# Spis treści

1	<b>W</b> st		<b>2</b> 2
2	Teo	ria informacji	<b>2</b>
	2.1	Miara informacji	2
	2.2	Entropia	2
		2.2.1 Entropia źródła	2
		•	3
3	Kod		3
	3.1	V	3
	3.2		3
	3.3	Jednoznaczna dekodowalność	3
		3.3.1 Nierówność Krafta	3
		3.3.2 Kod prefiksowy	3
	3.4	Kod natychmiastowy	3
4	Kon	npresja bezstratna	4
-	4.1		4
	4.2		4
	4.3		$\frac{4}{4}$
	4.4		4
	4.4		5
	4.6	V	5 5
	4.0	<u> </u>	5 5
			5
	4 7		$\frac{5}{6}$
	4.7	v v	
		<u>.</u>	6
	4.0		6
	4.8		6
		V	6
			7 7
			1 7
	4.0		1 7
	4.9	•	
		· · · · · · · · · · · · · · · · · · ·	7
		·	7
			8
	4.10		8
	-		8
	4.11		8
			8
			8
			9
		4.11.4 Poziomy rozdzielczości	9
5	Mad	cierzowa notacja kodów	9
6	Kor	ekcja błędów 1	0
	6.1	Kody parzystości	0
	6.2	Algorytm Luhna	0
	6.3	Kod powtórzeniowy	0
	6.4	Współczynnik informacji	
	6.5	Odległość Hamminga	
	6.6	Kody Hamminga	
	-		

6.7	Kody cykliczne	1.
6.8	Kody doskonałe	1
	Burst Error	

## 1 Wstęp

Wyróżniamy dwa rodzaje kompresji. W kompresji stratnej dopuszczalny jest pewien stopień straty informacji wejściowej. W kompresji bezstratnej nie jest to dopuszczalne.

## 1.1 "Prawo" Kompresji bezstratnej

Nie istnieje algorytm, który potrafi zmniejszyć rozmiar dowolnych danych

- Kompresja bezstratna musi być bijekcja
- $\bullet$  Dowolne dane przyjmują postać ciągu bitów długości n. Jest  $2^n$  takich ciągów.
- Danych krótszych niż n, np.: o jeden jest  $2^{n-1}$
- Nie da się stworzyć bijekcji z zbioru o mocy  $2^n$  do zbioru o mocy  $2^{n-1}$

Wniosek jest taki, że koniecznym jest konstruowanie kompresji bezstratnej na podzbiorach danych, takich jak np.: obrazów, dźwięków, tekstów.

## 2 Teoria informacji

Teoria informacji to dziedzina zajmująca się przetwarzaniem informacji. W teorii informacji mamy do czynienia z podstawowym założeniem, że zdarzenia niosą ze sobą pewną ilość informacji. Im rzadsze zdarzenie, tym bardziej informacyjne. Można to sobie wyobrazić jako zaskoczenie, jakie niesie ze sobą dane zdarzenie. Zaskoczenie wynikające, z tego że wstało słońce, jest mniejsze niż zaskoczenie wynikające z tego, że konkretny autobus się spóźnił.

### 2.1 Miara informacji

Miara informacji, która niesie ze soba zdarzenie A jest:

$$I(A) = -\log_x P(A)$$

gdzie x to baza systemu liczbowego. Jeśli miarą informacji jest bit to x=2. Jeśli zdarzenia A i B są niezależne to:

$$I(AB) = I(A) + I(B)$$

## 2.2 Entropia

Entropia to miara średniej informacji przekazywanej przez źródło. Kody jednoznacznie dekodowalne w modelu z niezależnymi wystąpieniami symboli muszą mieć średnią długość co najmniej równą entropii.

#### 2.2.1 Entropia źródła

Dla źródła danych S generującego ciąg X nad alfabetem  $\mathcal{A} = \{1, 2, \dots m\}$ 

$$H(S) = \lim_{n \to \infty} \frac{G_n}{n}$$

$$G_n = -\sum_i \cdots \sum_j P(X_1 = i, \dots, X_n = j) \log P(X_1 = i, \dots, X_n = j)$$

#### 2.2.2 Entropia Pierwszego Rzędu

Dla źródła informacji X, z zbiorem wiadomości (zdarzeń)  $A_1, \ldots, A_n$ , gdzie  $P(A_i)$  to prawdopodobieństwo wystąpienia zdarzenia  $A_i$  i zdarzenia są niezależne to entropia źródła to:

$$H(X) = \sum_{i=1}^{n} P(A_i)I(A_i)$$

## 3 Kodowanie

Kodowanie to przyporządkowanie elementom jakiegoś alfabetu ciągu binarnych. Przykładami kodowania są: ASCII, UTF-8 oraz inne. Typowym jest konstruowanie kodowania pod konkretny zestaw danych, optymalizując je pod kątem częstości występowania poszczególnych elementów.

## 3.1 Modelowanie danych

Rozważmy ciąg:  $a_n = 9, 11, 11, 11, 14, 13, 15, 17, 16, 17, 20, 21$ .  $\max(a_n) = 21$  stąd koniecznym jest 5 bitów na element. Ale jeśli wykorzystamy wzór  $e_n = a_n - n + 8$  do stworzenia nowego ciągu, to ten ciąg przyjmuje postać: 0, 1, 0, -1, 1, -1, 0, 1, -1, -1, 1, 1. Teraz wystarczą tylko 2 bity na zakodowanie elementu.

## 3.2 Średnia długość kodu

$$I = \sum_{i=1}^{n} p_i \cdot l_i$$

gdzie  $p_i$  to prawdopodobieństwo wystąpienia elementu i, a  $l_i$  to długość kodu dla elementu i.

#### 3.3 Jednoznaczna dekodowalność

Jeśli dla dowolnego ciągu znaków istnieje tylko jedno jego rozkodowanie to kod jest jednoznacznie dekodowalny. Aby sprawdzić czy kod jest jednoznacznie dekodowalny, należy zastosować następujący algorytm.

- 1. Stwórz listę słów kodowych.
- 2. Dla każdego elementu z listy sprawdź czy jedno jest prefiksem drugiego. Jeśli tak, dodaj sufiks drugiego słowa do listy, jeśli już go tam nie ma.
- 3. Jeśli na liście jest słowo kodowe, to kod nie jest jednoznacznie dekodowalny.

#### 3.3.1 Nierówność Krafta

Jeżeli  $\mathcal{C}$  jest kodem jednoznacznie dekodowalnym z n słowami to:

$$K(\mathcal{C}) = \sum_{i=1}^{n} 2^{-l_i} \le 1$$

Jest to warunek konieczny bycia kodem jednoznacznie dekodowalnym.

## 3.3.2 Kod prefiksowy

Kod w którym żadne słowo kodowe nie jest prefiksem innego słowa kodowego. Wszystkie kody prefiksowe są jednoznacznie dekodowalne.

#### 3.4 Kod natychmiastowy

Jest kodem pozwalającym stwierdzić w którym miejscu zakończone jest słowo kodowe w momencie odczytania ostatniej litery.

## 4 Kompresja bezstratna

Z reguły kompresja bezstratna opiera się na stworzeniu kodu, który pozwala na zakodowanie będące krótsze niż oryginalne dane. W tym celu wykorzystuje się różne techniki kodowania.

## 4.1 Statyczny Kod Huffmana

Kod Huffmana to kod prefiksowy o minimalnej średniej długości kodu. Są one optymalne wśród kodów prefiksowych. Dla alfabetu  $\mathcal{A}$  o długości n i prawdopodobieństwach wystąpienia  $p_1, \ldots, p_n$  algorytm tworzenia kodu Huffmana wygląda następująco: Znajdź dwa najrzadziej występujące elementy i połącz je w jeden element o prawdopodobieństwie  $p_1 + p_2$ . Rozróżnij je 0 lub 1. Powtórz ten krok na liście n-1 długiej aż zostanie jeden element.

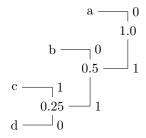


Diagram 1: Przykład kodu Huffmana dla P(a)=0.5, P(b)=0.25, P(c)=0.15, P(d)=0.1

## 4.2 Kodowanie Shannon-Fano

Dla symboli  $a_1, \ldots, a_n$  o prawdopodobieństwach  $p_1, \ldots, p_n$ , ustalmy kody długości  $l_n = \lceil -\log p_i \rceil$ . Następnie zdefiniujmy zmienne pomocnicze  $w_1, \ldots w_n$  jako:

$$w_1 = 0, w_j = \sum_{i=1}^{j-1} 2^{l_j - l_i}$$

Jeżeli  $\lceil \log w_j \rceil = l_j$  to j-te słowo kodowe jest binarną reprezentacją  $w_j$ . Jeżeli  $\lceil \log w_j \rceil < l_j$  to reprezentację uzupełniamy zerami z lewej strony.

Dla 
$$P(a) = \frac{1}{3}$$
,  $P(b) = \frac{1}{4}$ ,  $P(c) = \frac{1}{4}$ ,  $P(d) = \frac{1}{6}$  mamy:

$$l_a = 2, l_b = 2, l_c = 2, l_d = 3$$
 
$$w_1 = 0, w_2 = 2, w_3 = 2, w_4 = 6$$
 
$$kod(a) = 00, kod(b) = 01, kod(c) = 10, kod(d) = 110$$

## 4.3 Kodowanie Tunstalla

Chcemy stworzyć kod na n bitach dla  $a_1, \ldots, a_m$  symboli o prawdopodobieństwach  $p_1, \ldots, p_m$ . Tworzenie kodu Tunstalla polega na iteracyjnym wyborze ze zbioru symbolu o największym prawdopodobieństwie S i łączenie go z wszystkimi innymi symbolami tworząc symbole  $Sa_m$ , nadając im prawdopodobieństwa  $P \cdot p_m$ . Proces ten powtarzamy aż do uzyskania kodu o długości n.

#### 4.4 Kodowanie Golomba

Kody Golomba są parametryzowane liczbą m>0. Każda liczba n jest zapisywana za pomocą  $q=\lfloor\frac{n}{m}\rfloor$  oraz  $r=n-q\cdot m$  w postaci

$$(q)_1(r)_2$$

## 4.5 Dynamiczne kodowanie Huffmana

Głównym problemem kodowania Huffmana jest konieczność znania całego ciągu danych przed rozpoczęciem kodowania. Rozwiązaniem tego problemu jest dynamiczne kodowanie, gdzie stosujemy kodowanie Huffmana dla k+1 symbolu na podstawie kodowania dla k symboli. W tym celu tworzymy dynamicznie drzewo, gdzie każdy liść ma wagę równą ilości wystąpień danego symbolu. Drzewo zaczyna się od liścia z symbolem EOF o wadze 0.

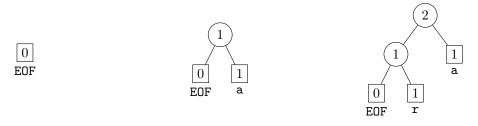


Diagram 2: Przykład kodowania dynamicznego

## 4.6 Problem kodowania uniwersalnego

Szukamy sposobu na kodowanie dowolnej liczby  $n \in \mathbb{N}$ . Problem polega na skonstruowaniu kodu, który będzie jednoznacznie dekodowalny i uniwersalny. To oznacza, że ma się skalować w nieskończoność.

#### 4.6.1 Kodowanie Eliasa

Kodowanie Eliasa to kodowanie uniwersalne, które wykorzystuje kodowanie unarne do zapisania długości kodu binarnego liczby n.

$$n = \lfloor \log_2(x) \rfloor + 1$$

 $\gamma$  Jest to najprostsze z kodowań Eliasa. Polega na zakodowaniu liczby x w postaci binarnej, a następnie dodaniu przed nią liczby n-1 zer.

$$\gamma(x) = 0^{n-1}(x)_2$$

$$(13)_{10} = 1101_2 \Rightarrow \gamma(13) = 0001101$$

 $\delta$  Cały trik kodu  $\delta$  polega na zakodowaniu długości kodu binarnego liczby x przy pomocy kodu  $\gamma$ . Istotnym trikiem jest usunięcie najstarszego bitu z zakodowanej liczby x.

$$\delta(x) = \gamma(n) + (x)_2$$
 (13)<sub>10</sub> = 1101<sub>2</sub>  $\Rightarrow$   $\delta$ (13) = 00100101

Jak widać, jest on bardziej efektywny dla większych liczb. Długość kodu  $\delta$  to  $2 \cdot \lceil \log_2(\lceil \log_2 x \rceil) \rceil - 1 + \lceil \log_2 x \rceil - 1$ .

 $\omega$  Jest to kodowanie rekurencyjne, które działa jak kodowanie  $\delta$ , ale w nieskończoność. Na koniec umieszczane jest 0, potem kodowana jest liczba k=x. Potem ten krok jest powtarzany dla k=n-1 gdzie n to liczba bitów z poprzedniego kroku.

$$(13)_{10} = 1101_2 \Rightarrow \omega(13) = 1111010$$

#### 4.6.2 Kodowanie Fibonacciego

Liczba Fibonacciego ma postać:

$$f_0 = f_1 = 1$$

$$f_n = f_{n-1} + f_{n-2} : n \ge 2$$

Kodowanie fibonacciego polega na reprezentacji liczby x jako sumę liczb fibonacciego.

$$x = \sum_{i=0}^{\infty} a_i \cdot f_i, a_i \in \{0, 1\}$$

$$(13)_{10} = f_7 = 1101_2 \Rightarrow Fib(13) = 0000011$$

## 4.7 Kodowanie arytmetyczne

Kodowanie arytmetyczne to kodowanie, które odwzorowywuje dowolny ciąg wejściowy na liczbę z zakresu [0,1). Głównym pomysłem stojącym za algorytmem, jest iteracyjne przypisywanie coraz to mniejszych przedziałów do kolejnych symboli ciągu wejściowego.

#### 4.7.1 Kodowanie zmiennoprzecinkowe

Dla zakresu początkowego [l, p) = [0, 1), ciągu symboli wejściowych  $a_j$ , dystrybuanty F(j) i prawdopodobieństw  $p_j$  algorytm wygląda następująco:

- d = p l
- $p = l + d \cdot F(j+1)$
- l = l + F(j)d

Powyższe kroki wykonujemy dla każdego symbolu ciągu wejściowego. Na koniec dostajemy zakres, z którego potem możemy wybrać dowolną liczbę jako wynik kodowania.

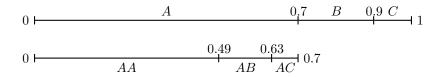


Diagram 3: Wizualizacja kodowania arytmetycznego

#### 4.7.2 Kodowanie całkowitoliczbowe

Liczbę z kodowania zmiennoprzecinkowego, można zakodować jako zbiór  $2^m$  wartości binarnych.

$$kod(0) = \overbrace{00...0}^{m}$$

$$kod(1) = \overbrace{11...1}^{m}$$

$$kod(0.5) = 1 \overbrace{00...0}^{m-1}$$

### 4.8 Kodowanie Słownikowe

#### 4.8.1 Statyczne kodowanie słownikowe

Zawczasu określamy jakiś słownik słów. Następnie przypisujemy każdemu słowu kod binarny. W ten sposób kodujemy cały tekst. Takie kodowanie ma sporo wad, głównie związanych z koniecznością przesyłania słownika oraz z słabą odpornością na błędy i zmienność danych wejściowych.

#### 4.8.2 LZ77

Słownikiem jest zakodowana/odkodowana część tekstu. W ten sposób jesteśmy bardzo elastyczni w zakresie zmiany danych wejściowych, oraz nie musimy przesyłać słownika. Kodem jest trójka (o,l,k) gdzie o to przesunięcie, l to długość, a k to kolejny znak. W ten sposób (0,0,n),(1,1,k) dekoduje się jako "nnk". Proces kodowania jest parametryzowany n i m, gdzie o < n i l < m. W oknie długości n szukamy najdłuższego prefiksu, który jest w cześci zakodowanej długości m.

Na przykład, w stanie w którym mamy zakodowane "abcdefgh", trójka (4,3,i) oznacza "efgi", ponieważ cofamy się o 4 litery do tyłu, bierzemy 3 kolejne litery i dodajemy na koniec kolejna literę i.

#### 4.8.3 LZ78

Istnieje osobny słownik, do którego trafiają kolejne słowa. Podczas kodowania kolejno szukamy w słowniku najdłuższego słowa, które jest prefiksem ciągu wejściowego. Jeśli nic nie znajdziemy to dodajemy pierwszą literę do słownika, lecz jeśli znajdziemy taki prefiks, to kodujemy go jako indeks w słowniku, wraz z kodem następnej litery. Zatem kod (0,k), (1,a)(2,b) oznacza "kkakab", a słownik s zawiera s(1) = k, s(2) = ka, s(3) = kab.

#### 4.8.4 LZW

Ta wersja algorytmu pozbywa się drugiego elementu pary z kodowania LZ78. Z kolei potrzebny jest słownik początkowy zawierający wszystkie możliwe symbole. Poza tą mała różnicą, algorytm jest identyczny z LZ78. Zatem ze słownikiem s gdzie s(1) = a, s(2) = b, s(3) = c, kod: 3245 znaczy "cbcbbc", ponieważ s(4) = cb po pierwszym kroku.

## 4.9 bzip2

#### 4.9.1 Kodowanie tabelą

Mając blok danych o długości n, tworzymy wszystkie n rotacji tego bloku. Następnie sortujemy je leksykograficznie. W ten sposób otrzymujemy blok transformowany.

0	е	1	l	О	h
1	h	e	l	l	О
2	1	1	О	h	е
3	1	О	h	e	1
4	0	h	е	l	1

Tabela 1: Przykład bloku transformowanego dla słowa "hello"

#### 4.9.2 Kodowanie szybkie

Alternatywnie zamiast tworzenia ogromnej tabeli, wystarczy stworzyć pierwszą i ostatnią kolumnę. Pierwszą kolumnę tworzy się przez posortowanie słowa leksykograficznie (w przypadku konfliktu patrzymy na kolejne litery). Ostatnia kolumnę tworzymy poprzez zapisanie litery poprzedzającej dana literę w oryginalnym słowie. Na pod-

е	h
h	О
11	e
lo	1
О	l

Tabela 2: Wygenerowana pierwsza i ostatnia kolumna dla słowa "hello"

stawie tej tabeli zapisujemy numer wiersza, w którym znajduje się oryginalne słowo, oraz ostatnią kolumnę. W ten sposób uzyskujemy kod 1, "hoell".

#### 4.9.3 Dekodowanie

Mając tylko te dane, jesteśmy bardzo łatwo w stanie odtworzyć oryginalne słowo. Najpierw sortujemy nasz kod leksykograficznie, zapamiętując indeksy. Mając taką tabelę, następnie konstruujemy ciąg, traktując tabelę jak

0	1	2	3	4
е	h	l	l	О
2	0	3	4	1

Tabela 3: Tabela dekodowania dla kodu 1, "hoell"

permutację, zaczynając od indeksu zawartego w kodzie. W naszym przypadku powstaje permutacja cykliczna (1,0,2,3,4). Wykorzystując tę permutację, odtwarzamy oryginalne słowo.

#### 4.9.4 Move to Front

Zaczynamy od tabeli liter posortowanych z słowa wejściowego. Następnie dla każdej litery w słowie, kodujemy ją jako jej indeks w tabeli, a następnie literę w tabeli przesuwamy na początek. W ten sposób kodujemy słowo "hello" jako "11203". Taki kod ma mniejszą entropię i jest łatwiej kompresowalny.

### 4.10 V.42bis

To jest standard, głównie wykorzystywany w modemach, do kompresji i korekcji błędów w sieciach telefonicznych. Może działać w dwóch trybach: przezroczystym (bez kompresji) i z kompresją (LZW).

Zaczynamy z słownikiem, o wcześniej ustalonej, negocjowalnej, wielkości. Wyróżniamy w komunikacji trzy specjalne kody:

- 1. ETM przejście do trybu przezroczystego
- 2. FLUSH oczyszczenie danych
- 3. STEPUP zwiększenie rozmiaru słownika ×2

Gdy liczba elementów w słowniku przekroczy wartość dozwoloną, wysyłany jest kod STEPUP. Gdy słownik jest pełny, wysyłany jest kod FLUSH. W ten sposób, mamy zmienny, dynamiczny słownik, który dostosowuje się do danych wejściowych po stronie nadawcy i odbiorcy.

## 4.11 Kodowanie predykcyjne

W tekstach naturalnych symbole bardzo często zależą od siebie. Można wykorzystać informację o prawdopodobieństwach wystąpienia symboli, pod warunkiem wystąpienia poprzednich symboli. Dla dłuższego okna kontekstowego, kodowanie predykcyjne jest bardziej skuteczne, lecz wymaga większej ilości pamięci.

### 4.11.1 PPM

Dla kontekstu długości n, algorytm PPM polega na stworzeniu drzewa kontekstowego, które przechowuje informacje o prawdopodobieństwach wystąpienia poszczególnych symboli. Szczególnym symbolem w tym drzewie jest ESC, który oznacza brak wystąpienia symbolu w danym kontekście. W ten sposób możemy zbudować drzewo, które pozwala na przewidywanie kolejnych symboli, które potem można wykorzystać do zbudowania dynamicznego kodowania Huffmana.

#### 4.11.2 CALIC

Algorytm CALIC jest algorytmem kompresji obrazów, który wykorzystuje kodowanie predykcyjne. Dla każdego piksela obrazu, wykorzystuje się kontekst pikseli wokół niego, aby przewidzieć wartość piksela. Chcemy wiedzieć czy w sąsiedztwie piksela są krawędzie pionowe lub poziome.

$$d_h = |W - WW| + |N - NW| + |NE - N|$$

$$d_v = |W - NW| + |N - NN| + |NE - NNE|$$

Następnie na podstawie tych dwóch wartości, tworzymy  $\widehat{X}$  i kodujemy różnicę między X a  $\widehat{X}$ .

Kontekst	Symbol	Licznik
th	ESC	1
	i	1
hi	ESC	1
	s	1
is	ESC	1
	-	1
S-	ESC	1
	i	1
-i	ESC	1
	s	1

Tabela 4: Przykład drzewa kontekstowego dla słowa "this-is"

		NN	NNE
	NW	N	NE
WW	W	X	E

Diagram 4: Kontekst dla algorytmu CALIC

#### 4.11.3 JPEG-LS

JPEG-LS to standard kompresji obrazów, podobny do CALIC, który też wykorzystuje kodowanie predykcyjne.

NW	N
W	X

Diagram 5: Kontekst dla algorytmu JPEG-LS

1. 
$$\widehat{X} = W$$

$$2. \ \widehat{X} = N$$

3. 
$$\hat{X} = NW$$

$$4. \ \widehat{X} = N + W - NW$$

5. 
$$\hat{X} = N + \frac{W - NW}{2}$$

6. 
$$\hat{X} = W + \frac{N - NW}{2}$$

7. 
$$\hat{X} = \frac{N+W}{2}$$

Wśród tych siedmiu możliwości, wybieramy tę, która daje najmniejszą różnicę między X a  $\hat{X}$  i podobnie jak dla CALIC kodujemy ciąg różnic.

#### 4.11.4 Poziomy rozdzielczości

Kodujemy obraz wysyłając średni kolor kwadratów o rozmiarze  $2^k \times 2^k$  a następnie różnice między tą średnią a średnią kwadratow  $2^{k-1} \times 2^{k-1}$ . Kończymy na pojedynczych pikselach. Różnice między tymi kwadratami łatwo się kompresuje bo są małe.

## 5 Macierzowa notacja kodów

Macierz generująca, to macierz przez którą mnożymy wektor danych, aby uzyskać kod. Macierz parzystości to macierz, przez którą mnożymy kod, aby uzyskać wektor zer. Macierz generująca i parzystości są ze sobą powiązane. Syndrom to niezerowy wynik mnożenia wektora kodu przez macierz parzystości.

## 6 Korekcja błędów

## 6.1 Kody parzystości

Do każdego bloku danych dodawany jest bit parzystości, który przyjmuje wartość 1, gdy liczba jedynek w bloku jest nieparzysta. W przeciwnym razie przyjmuje wartość 0. W ten sposób jesteśmy w stanie wykryć jeden błąd w bloku danych.

$$G(n) = \underbrace{\begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1 \end{bmatrix}}_{\times n} \times n + 1$$

$$H(n) = \underbrace{\begin{bmatrix} 1 & \dots & 1 \end{bmatrix}}_{\times n+1}$$

## 6.2 Algorytm Luhna

Jest to algorytm wykorzystywany do weryfikacji poprawności numerów z cyfrą kontrolną. Polega on na pomnożeniu co drugiej cyfry przez 2, wyeliminowaniu wszystkich liczb dwucyfrowych przez dodanie ich cyfr, a następnie dodaniu wszystkich cyfr. Na koniec dobierana jest cyfra kontrolna, tak aby suma wszystkich cyfr była podzielna przez 10.

## 6.3 Kod powtórzeniowy

Kod powtórzeniowy polega na powtórzeniu bloku danych k razy. W ten sposób jesteśmy w stanie wykryć k-1 błędów. Kod powtórzeniowy jest bardzo nieskuteczny, ponieważ wymaga k razy więcej miejsca na przechowywanie danych.

$$G(n) = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right\} \times n$$

$$H(n) = \underbrace{\begin{bmatrix} 1 & 1 & 0 & \dots & 0 \\ 1 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & \dots & 1 \end{bmatrix}}_{\times n} \right\} \times n - 1$$

## 6.4 Współczynnik informacji

Dla kodu  $\mathcal{C}$  długości n współczynnikiem informacji nazywamy:

$$\frac{1}{n}\log|\mathcal{C}|$$

Dla kodu powtórzeniowego k współczynnik informacji wynosi:  $\frac{1}{n}$ . Dla kodów parzystości współczynnik informacji wynosi  $\frac{n}{n+1}$ .

### 6.5 Odległość Hamminga

$$d(a,b) = \sum_{i=1}^{n} a_i \neq b_i$$

Dla kodu K minimalną odległością tego kodu nazywamy minimalną odległość Hamminga tego kodu. Kod K wykrywa t błędów jeśli jego minimalna odległość jest mniejsza niż t. Z kolei ten sam kod koryguje te błedy jeśli jego minimalna odległość jest większa niż 2t.

## 6.6 Kody Hamminga

Kody doskonałe dla korekcji jednego błędu. Dla długości kodu  $n = 2^m - 1$ , mają liczbę bitów informacji k = n - m. Najprostszą macierzą Hamminga dla n powyższego, jest taka kodująca kolejne liczby binarne od 1 do n. Dla m = 3:

$$H_H(3) = \begin{bmatrix} 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix}$$

To jest macierz parzystości dla kodu Hamminga dla m=3. Taką macierz można następnie zamienić na macierz generującą, poprzez potraktowanie jej jako macierzy z metody Gaussowskiej, w tym wypadku równoważnej z:

$$x_5 = x_2 + x_3 + x_4$$
  
 $x_6 = x_1 + x_3 + x_4$   
 $x_7 = x_1 + x_2 + x_4$ 

Następnie wystarczy potraktować ten układ równań jako macierz, z 7 wierszami, z czego pierwsze 4 (ilość kolumn) są jednostkowe, a ostatnie 3 odpowiadają układowi równań.

$$G_H(3) = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 \end{bmatrix}$$

Dla wektora informacji x, kod liczymy jako: k(x) = G(K)x

## 6.7 Kody cykliczne

Kod liniowy nazywamy cyklicznym wtedy i tylko wtedy, jeśli dla każdego słowa kodowego  $v_0v_1...v_n$  cykliczne przesunięcie  $v_nv_0v_1...v_{n+1}$ . Kod parzystości i powtórzeniowy są kodami cyklicznymi.

Kody cykliczne można reprezentować przy pomocy wielomianów. W takiej reprezentacji, dodawanie słów kodowych jest równoważne dodawaniu reprezentujących wielomianów.

$$a_0a_1 \dots a_n \Rightarrow a(x) = a_0 + a_1x + \dots + a_nx^n \in \mathbb{Z}_2$$

Każdy nietrywialny (n, k)-kod cykliczny (kod długości n z k bitami) zawiera słowo kodowe g(x) stopnia n - k. Dla takiego kodu:

$$G(k) = \begin{bmatrix} g(x) \\ xg(x) \\ \vdots \\ x^{k-1}g(x) \end{bmatrix}$$

#### 6.8 Kody doskonałe

Binarny (n, k)-kod jest doskonały dla t błędów, jeśli ma minimalną odległość równą 2t + 1 oraz spełniona jest:

$$2^{n-k} = \sum_{i=0}^{t} \binom{n}{i}$$

Przykładem kodu doskonałego jest kod Golay. Jest to (23, 12)-kod.

$$g(x) = 1 + x^2 + x^4 + x^5 + x^6 + x^{10} + x^{11}$$

Odległość minimalna tego kodu to 7 i koryguje 3 błędy.

#### 6.9 Burst Error

Burst error to ciąg błędów, długości t. Kod dualny do kodu Hamminga z  $g(x) = 1 + x^2 + x^3 + x^4$  jest (7,3)-kodem korygującym 2 burst errors.