

# 1 Analiza Matematyczna

## 1.1 Pochodna funkcji złożonej

$$h = f \circ g \quad h'(x) = f'(g(x)) \cdot g'(x)$$

### Przykład 1.1

Pochodną funkcji  $f(x) = (x^9 + x)^9$  jest:

$$f'(x) = 9(x^9 + x)^8 \cdot (9x^8 + 1)$$

## 1.2 Jakobian

$$f : \mathbb{R}^n \rightarrow \mathbb{R}^m \quad f(x) = (f_1(x), \dots, f_m(x))$$

Dla powyższej funkcji, macierz Jakobiego to:

$$J_{ij} = \frac{\partial f_i}{\partial x_j} \quad J_f = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

Jakobian, to wyznacznik macierzy Jakobiego.

### Przykład 1.2

$$f(x, y, z) = (x, y, z) \quad f_1(x, y, z) = x \quad f_2(x, y, z) = y \quad f_3(x, y, z) = z$$

$$J_f = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\det(J_f) = 1$$

# 2 Rachunek Prawdopodobieństwa

Gęstością pewnego zdarzenia nazywamy funkcję  $f : \Omega \rightarrow [0, 1]$ , która dla każdego  $x \in \Omega$  zwraca prawdopodobieństwo zdarzenia  $x$ . Wymogiem formalnym gęstości, jest to, że się sumuje do 1:

$$\sum_{x \in \Omega} f(x) = 1 \quad \int_{\Omega} f(x) dx = 1$$

### Przykład 2.1

Na przykład, dla zmiennej losowej  $X$ , określonej przez wynik losowego rzutu kością, prawdopodobieństwo zdarzenia  $X = k$  wynosi  $\frac{1}{6}$ , gdzie  $k$  to wynik rzutu. Stąd też,  $f(x) = \frac{1}{6}$  dla  $x = k$ .

Dystrybuenta, to funkcja  $F : \Omega \rightarrow [0, 1]$ , ściśle związana z gęstością:

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

W pewnym sensie, reprezentuje prawdopodobieństwo, że zmienna losowa  $X$  ma wartość mniejszą lub równą  $x$ .

## Przykład 2.2

Wracając do naszego przykładu z kością, dystrybuanta  $F(x)$  dla  $x = k$  wynosi

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt = \int_{-\infty}^k \frac{1}{6}dt = \frac{k}{6}$$

W tym przypadku,  $F(x)$  jest funkcją skokową, która przyjmuje wartość 0 dla  $x < 1$ ,  $1/6$  dla  $x = 1$ ,  $2/6$  dla  $x = 2$ , itd.

**Dystrybuanta nie musi się sumować do 1**, wręcz przeciwnie, ale musi być niemalejąca, prawostronnie ciągła (lub lewostronnie, ale nie może mieć dziur).


$$\lim_{x \rightarrow \infty} F(x) = 1 \quad \lim_{x \rightarrow -\infty} F(x) = 0$$

## Przykład 2.3

Poniższa funkcja  $F(x)$  jest dystrybuantą:

$$F(x) = \begin{cases} 0 & x < 1 \\ 1 - \frac{1}{x^2} & x \geq 1 \end{cases}$$

Ponieważ jest prawostronnie ciągła, niemalejąca i ograniczona przez 1.



### 3 Algebra Liniowa

Wektor to element przestrzeni wektorowej  $V$ , czyli  $x \in V$ . Wektory są ortogonalne, jeśli ich iloczyn skalarny jest równy 0, czyli  $x \cdot y = 0$  dla dowolnych  $x, y \in V$ .

## Przykład 3.1

Wektory  $(1, 1, 1)$  i  $(-2, 1, 1)$  są ortogonalne, ponieważ ich iloczyn wynosi:

$$\begin{bmatrix} 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} -2 \\ 1 \\ 1 \end{bmatrix} = 0$$

Normą indukowaną w  $\mathbb{R}^n$  jest funkcja  $\|x\| = \sqrt{x^T \cdot x} = \sqrt{\langle x|x \rangle}$ .

#### 3.1 Wyznacznik

$$\det A = a_{11} \det A_{11} - a_{12} \det A_{12} + \dots + (-1)^{n-1} a_{nn} \det A_{nn}$$

gdzie  $A_{ij}$  to macierz  $A$  z usuniętym wierszem  $i$  i kolumną  $j$ .

**Przykład 3.2**

Dla macierzy  $A$  rozmiaru  $3 \times 3$ :

$$\det A = a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{12} \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} + a_{13} \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix}$$

Dla macierzy  $A$  rozmiaru  $4 \times 4$ :

$$\det A = a_{11} \begin{vmatrix} a_{22} & a_{23} & a_{24} \\ a_{32} & a_{33} & a_{34} \\ a_{42} & a_{43} & a_{44} \end{vmatrix} - a_{12} \begin{vmatrix} a_{21} & a_{23} & a_{24} \\ a_{31} & a_{33} & a_{34} \\ a_{41} & a_{43} & a_{44} \end{vmatrix} + a_{13} \begin{vmatrix} a_{21} & a_{22} & a_{24} \\ a_{31} & a_{32} & a_{34} \\ a_{41} & a_{42} & a_{44} \end{vmatrix} - a_{14} \begin{vmatrix} a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \\ a_{41} & a_{42} & a_{43} \end{vmatrix}$$

**3.2 Odwzorowania liniowe**

Odwzorowanie liniowe  $T : V \rightarrow U$ , to macierzowa transformacja

$$T(x) = Ax$$

gdzie  $A$  to macierz  $\dim V \times \dim U$ , a  $x$  to wektor  $\dim V$ -elementowy.

$$\ker T = \{x : T(x) = 0\} \quad \text{Im } T = \{T(x) : x \in V\}$$

Zbiór wektorów jest liniowo niezależny, gdy nie istnieje żadna kombinacja liniowa tych wektorów, która daje wynik równy 0.

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n = 0$$

Ranga macierzy  $A$  to maksymalna liczba liniowo niezależnych wierszy (lub kolumn) macierzy  $A$ , czyli  $\text{rank}(A) = \dim \text{Im } T$ . Formalnie; wymiar przestrzeni rozpiętej przez jej wiersze. Jeśli ranga jest równa zero, to macierz wysyła wektory do zera, czyli  $\ker T = V$ .

Operator liniowy jest różnowartościowy wtedy i tylko wtedy, gdy  $\ker T = \{0\}$ . Macierz przekształcenia musi wtedy też mieć rangę  $n$ , gdzie  $n$  to liczba wierszy macierzy  $A$ .

$$\dim \mathbb{R}^n = n \quad \dim V = \dim \text{Im } T + \dim \ker T$$

**Przykład 3.3**

Jeśli wiemy, że  $T : \mathbb{R}^4 \rightarrow \mathbb{R}^3$ , to wiemy, że macierz  $T$  ma rozmiar  $3 \times 4$ .

$$T(x) = \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + a_{14}x_4 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + a_{24}x_4 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + a_{34}x_4 \end{bmatrix}$$

$T$ , może mieć nietrywialne  $\ker T \neq \{0\}$ , może mieć rangę w  $[0, 4]$  bo ma 4 kolumny, lecz nie może być różnowartościowe, ponieważ:

$$\dim V = \dim \text{Im } T + \dim \ker T \Rightarrow 4 = 3 + \dim \ker T \Rightarrow \dim \ker T = 1$$

Więc  $\ker T \neq \{0\}$ , więc  $T$  nie jest różnowartościowy.

Aby macierz była odwracalna, to musi być kwadratowa, czyli  $n \times n$ , gdzie  $n$  to liczba wierszy, jej ranga musi być maksymalna  $\dim \text{Im } T = n$ , więc  $\dim \ker T = 0$ , czyli  $\ker T = \{0\}$ , i jej wyznacznik musi być różny od zera, czyli  $\det T \neq 0$ .

**3.3 Wartości własne**

Dla równania:

$$A|\psi\rangle = \lambda|\psi\rangle$$

$|\psi\rangle$  jest wektorem własnym macierzy  $A$ , a  $\lambda$  jest jej wartością własną - odpowiadającą wektorowi własnemu  $|\psi\rangle$ .

$$\det(A - \lambda I) = 0 \quad (A - \lambda I) |\psi\rangle = 0$$

Wielomian charakterystyczny macierzy to:

$$p_A(t) = (t - \lambda_1)^{k_1} (t - \lambda_2)^{k_2} \dots (t - \lambda_n)^{k_n} = 0 \quad p_A(A) = 0$$

jest to zazwyczaj pochodna poszukiwania wartości i wektorów własnych.

### 3.4 Rozkłady

Każdą rzeczywistą, symetryczną macierz dodatnio określonej formy kwadratowej można zapisać jako iloczyn macierzy dolnotrójkątnej i jej transpozycji. Nazywamy to rozkładem Choleskiego:

$$A = LL^T$$

## 4 Statystyka

Estymator, to funkcja  $\hat{\theta}(X)$ , która na podstawie próbki  $X \subset U$ , gdzie  $U$  to cała populacja, estymuje wartość parametru  $\theta(U)$ .

Estymator jest nieobciążony, jeśli:

$$\mathbb{E}[\hat{\theta}(X)] = \theta(U)$$

czyli wartość oczekiwana estymatora jest równa wartości parametru. Mówimy wtedy, że  $\hat{\theta}(X)$  jest estymatorem największej wiarygodności (ENW).

#### Przykład 4.1

Dla próbki  $X \subset U$ , gdzie  $U$  to cała populacja, estymator średniej  $\hat{\mu}(X) = \bar{X}$ , jest nieobciążonym estymatorem średniej  $\mu(U)$ , ponieważ:

$$\mathbb{E}[\hat{\mu}(X)] = \mu(U)$$

Intuicyjnie, estymator jest nieobciążony, ponieważ dla odpowiednio dużej próbki  $X$ , średnia z próbki będzie bliska wartości parametru  $\mu(U)$ .

### 4.1 Charakterystyka próbek losowych

Dla zmiennej losowej  $X$ ,

- $\mathbb{E}[X] = \mu$  - wartość oczekiwana to średnia
- $\text{Var}[X] = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \text{Cov}[X, X] = \sigma^2$
- $\sigma = \sqrt{\text{Var}[X]}$  - odchylenie standardowe

### 4.2 Rozkład Normalny

Rozkład normalny, lub rozkład Gaussa, jest rozkładem prawdopodobieństwa zdefiniowanym na rzeczywistych liczbach rzeczywistych. Dla zmiennej losowej  $X$  o rozkładzie normalnym:

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

gdzie  $\mu$  to średnia, a  $\sigma^2$  to wariancja.

Typowy estymator wariancji z próby:

$$\hat{\sigma}^2(X) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \mathbb{E}[\hat{\sigma}^2(X)] = \frac{n}{n-1} \text{Var}[X]$$

jak widać, jest obciążony, albowiem  $\mathbb{E}[\hat{\sigma}^2(X)] \neq \text{Var}[X]$ . Estymator nieobciążony wariancji to:

$$S^2(X) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \mathbb{E}[S^2(X)] = \text{Var}[X]$$

### 4.3 Metoda najmniejszych kwadratów

Jest to metoda estymowania parametrów modelu. Model ma postać  $f(x, \theta)$ , gdzie  $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ . Celem jest znalezienie wartości  $\theta$  dla której minimalizowane jest:

$$r_i = y_i - f(x_i, \theta) \quad S = \sum_{i=1}^n r_i^2$$

Rozwiązaniem problemu jest znalezienie takich  $m$ , dla których gradient  $S$  jest równy zero:

$$\nabla_{\theta} S = 0$$