

Spis treści

1	Model McCullocha-Pittsa	1
1.1	Przykład	1
1.2	Reprezentacja wektorowa	2
2	Liniowa separowalność	2
2.1	Przykład	2
3	Associatron	2
3.1	Liniowy model pamięci	2
3.2	Cel	3
3.3	Macierz wag	3
3.4	Liniowa funkcja asocjacyjna	3
3.5	Nieliniowa funkcja asocjacyjna	3

1 Model McCullocha-Pittsa

Jest to model matematyczny mający naśladować działanie fizjologicznych neuronów. Składa się on z n wejść u_i o wagach w_i i jednego wyjścia y . Neuron aktywuje się, gdy suma iloczynów wejść i wag jest większa od pewnej wartości progowej θ .

$$n_i, y \in \{0.0, 1.0\} \subset \mathbb{R}$$

$$w_i, \theta \in \mathbb{R}$$

$$f(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases}$$

$$y(\vec{u}, \vec{w}) = f\left(\sum_{i=1}^n w_i u_i - \theta\right)$$




Diagram 1: Wizualizacja modelu McCullocha-Pittsa

1.1 Przykład

u_1	u_2	y
0	0	0
0	1	0
1	0	0
1	1	1

Tabela 1: Tabela prawdy dla funkcji logicznej AND

- $u_1 = u_2 = 0 \rightarrow y = 0 = f(-\theta) \leftrightarrow \theta \geq 0$
- $u_1 = 0, u_2 = 1 \rightarrow y = 0 = f(w_2 - \theta) \leftrightarrow w_2 < \theta$
- $u_1 = 1, u_2 = 0 \rightarrow y = 0 = f(w_1 - \theta) \leftrightarrow w_1 < \theta$

$$\bullet u_1 = u_2 = 1 \rightarrow y = 1 = f(w_1 + w_2 - \theta) \leftrightarrow w_1 + w_2 \geq \theta$$

$$\theta = 3, w_1 = 2, w_2 = 2$$

1.2 Reprezentacja wektorowa

$$\vec{u} = (u_1, u_2, \dots, u_n)$$

$$\vec{w} = (w_1, w_2, \dots, w_n)$$

$$y(\vec{u}, \vec{w}) = f(\vec{w} \cdot \vec{u} - \theta)$$

2 Liniowa separowalność

$$U_- = \{\vec{u}_1, \dots, \vec{u}_n\} \subset \mathbb{R}^n$$

$$U_+ = \{\vec{u}_{n+1}, \dots, \vec{u}_{n+m}\} \subset \mathbb{R}^n$$

$$U_- \cap U_+ = \emptyset$$

Mówimy, że zbiory wektorów (wejść) U_- i U_+ są liniowo separowalne, jeśli istnieje jakikolwiek \vec{w} taki, że: $\vec{w} \cdot \vec{u} < 0 : \vec{u} \in U_-$ oraz $\vec{w} \cdot \vec{u} > 0 : \vec{u} \in U_+$. Innymi słowy jeśli istnieje hiperpłaszczyzna, która dzieli zbiory U_- i U_+ .

2.1 Przykład

Dla bramki AND mamy:

$$U_- = \{(0, 0), (0, 1), (1, 0)\}, U_+ = \{(1, 1)\}$$

$$\vec{w} = (2, 2), \theta = 3$$




Diagram 2: Liniowa separowalność dla bramki AND

3 Associatron

Jest to model pamięci asocjacyjnej, skojarzeniowej, który pozwala na kojarzenie danych. W tym modelu dane reprezentujemy wektorami binarnymi. Jako, że de facto tworzymy macierz, to dowolne dane można asocjować.

3.1 Liniowy model pamięci

$$U = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_n\} \in \mathbb{R}^n$$

$$\vec{u}_t = (u_{t1}, u_{t2}, \dots, u_{tn}), u_{ti} \in \{0, 1\}$$

3.2 Cel

Celem modelu jest stworzenie funkcji, która dla danego wektora \vec{u}_t zwróci wektor \vec{u}_s , który jest najbardziej podobny do \vec{u}_t .

$$\varphi : U \rightarrow Y$$

$$U, Y \in \mathbb{R}^n$$

3.3 Macierz wag

$$\vec{y}_t = W \cdot \vec{u}_t$$

$$W = [w_{ij}] = \frac{1}{n} \sum_{t=1}^N \vec{y}_t \cdot \vec{u}_t^T$$

Macierz wag jest stała dla danego zbioru wektorów U .

3.4 Liniowa funkcja asocjacyjna

Zakładając, że wszystkie wektory w U są ortogonalne ($\vec{u}_t \perp \vec{u}_s \leftrightarrow \vec{u}_t \cdot \vec{u}_s = 0$) to wówczas:

$$\varphi(\vec{u}_i) = W \cdot \vec{u}_i = \frac{1}{n} \sum_{\vec{u}_t \in U} \vec{y}_t (\vec{u}_t \cdot \vec{u}_i) = \frac{1}{n} \cdot \vec{y}_i \cdot \vec{u}_i \cdot \vec{u}_i = \frac{1}{n} \cdot \vec{y}_i \cdot n = \vec{y}_i$$

Czyli dla każdego wektora \vec{u}_i zwracamy wektor \vec{y}_i . W istocie w powyższym równaniu szukamy takiego wektora w U , który po pomnożeniu przez wejście, nie będzie ortogonalny, czyli zwróci n .

$$\vec{u}_t \cdot \vec{u}_t = u_t^T u_t = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \cdot [1 \quad 1 \quad \dots \quad 1] = n$$

3.5 Nieliniowa funkcja asocjacyjna

Ograniczenie, że wektory w U są ortogonalne jest bardzo silne. W praktyce nie jesteśmy w stanie tego założyć. Zatem możemy wprowadzić funkcję φ' , która pozwala na pewnego rodzaju błąd.

$$\varphi'(\vec{u}_t) = \begin{bmatrix} \text{sgn}(x_1) \\ \text{sgn}(x_2) \\ \vdots \\ \text{sgn}(x_n) \end{bmatrix}, \vec{x} = W \cdot \vec{u}_t$$

$$\text{sgn}(x) = \begin{cases} -1 & x < 0 \\ 1 & x \geq 0 \end{cases}$$