

Spis treści

1	Rozkłady	1
1.1	Rozkład dwumianowy	1
1.2	Rozkład normalny	1
1.3	Rozkład chi-kwadrat	2
1.4	Rozkład wykładniczy	2
1.5	Rozkład t-Studenta	2
1.6	F-Snedecora	2
2	Statystyka Opisowa	2
2.1	Rodzaje statystyk opisowe	2
2.2	Tendencja centralnej rozkładu empirycznego	2
2.3	Charakterystyki rozrzutu rozkładu empirycznego	3
3	Model statystyczny	3
4	Estymacja Punktowa	3
4.1	Metoda momentów	3
4.2	Metoda największej wiarygodności	3
4.3	Przykład	3
4.4	Estymatory nieobciążone	3
4.5	Estymator modelu wykładniczego	3
4.6	Estymator modelu normalnego	3
4.7	Metoda monte carlo	4
4.8	Metoda bootstrap	4
5	Przedziały ufności	4
6	Test t-Studenta	4
6.1	Dla jednej próby	4
6.2	Dla dwóch prób	4
6.2.1	Błąd	5
6.2.2	Próby niezależne z jednorodnymi wariancjami	5
6.2.3	Próby niezależne z różnymi wariancjami	5
7	Test F	6

1 Rozkłady

1.1 Rozkład dwumianowy

Rozkład dwumianowy to rozkład sumy n zmiennych losowych o rozkładzie Bernoulliego. Zmienna losowa X ma rozkład dwumianowy z parametrami n i p , zatem:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

gdzie $\binom{n}{k}$ to liczba kombinacji k sukcesów w n próbach.

1.2 Rozkład normalny

Rozkład normalny (Gaussa) jest jednym z najważniejszych rozkładów statystycznych. Jest on określony przez dwa parametry: wartość oczekiwaną μ i wariancję σ^2 . Gęstość rozkładu normalnego jest dana wzorem:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

1.3 Rozkład chi-kwadrat

Niech X_1, X_2, \dots, X_n będą niezależnymi zmiennymi losowymi o rozkładzie normalnym $N(0, 1)$. Wtedy zmienna losowa $X = \sum_{i=1}^n X_i^2$ ma rozkład chi-kwadrat ($X \sim \chi(n)$) z n stopniami swobody.

$$f(x) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}$$

1.4 Rozkład wykładniczy

Jest to rozkład zmiennej, która opisuje czas między zdarzeniami w procesie Poissona. Zmienna losowa X ma rozkład wykładniczy z parametrem λ , zatem:

$$f(x, \lambda) = \begin{cases} \lambda e^{-\lambda x} & \text{dla } x \geq 0 \\ 0 & \text{dla } x < 0 \end{cases}$$

1.5 Rozkład t-Studenta

Niech $X \sim N(0, 1)$ oraz $Y \sim \chi^2(n)$ będą niezależnymi zmiennymi losowymi. Wtedy zmienna losowa:

$$\frac{X}{\sqrt{Y/n}}$$

ma rozkład t-Studenta z n stopniami swobody. Funkcja gęstości rozkładu t-Studenta jest dana wzorem:

$$f(x, n) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$$

1.6 F-Snedecora

Niech $X \sim \chi^2(n)$, $Y \sim \chi^2(m)$ będą niezależnymi zmiennymi losowymi. Wtedy zmienna losowa:

$$\frac{X/n}{Y/m}$$

ma rozkład F-Snedecora z n i m stopniami swobody. Funkcja gęstości rozkładu F-Snedecora jest oznaczana przez $F(n, m)$.

2 Statystyka Opisowa

Niech $X' = \{x_1, x_2, \dots, x_n\}$ będzie zbiorem n obserwacji zmiennej losowej X . Zadaniem statystyki opisowej jest prezentacja rozkładu zmiennej losowej X w próbce X' .

2.1 Rodzaje statystyk opisowe

- Klasyczne - uśredniające wartość próbki. Na przykład momenty zwykle r -tego rzędu:

$$m_r = \frac{1}{n} \sum_{i=1}^n x_i^r$$

- Pozycyjne - oparte na pozycjach obserwacji w próbce. Na przykład mediana, kwartyle, percentyle.

2.2 Tendencja centralnej rozkładu empirycznego

- Średnia arytmetyczna:

$$\bar{X}' = \frac{1}{n} \sum_{i=1}^n x_i$$

- Mediana

2.3 Charakterystyki rozrzutu rozkładu empirycznego

- Odchylenie standardowe:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X}')^2}$$

- Współczynnik zmienności:

$$v = \frac{s}{\bar{X}'} \cdot 100\%$$

3 Model statystyczny

Jeżeli próba X' jest reprezentatywna, to można na jej podstawie wnioskować na temat populacji z której pochodzi. Aby określić zachowanie zmiennej losowej X w populacji, stosuje się model statystyczny. Zatem traktujemy wektor X' jako realizację zmiennej losowej X .

4 Estymacja Punktowa

Niech X' będzie próba populacji o rozkładzie P_θ gdzie $\theta \in \Theta$ jest parametrem. Estymatorem parametru θ nazywamy statystykę $\hat{\theta}: X' \rightarrow \Theta$ która pozwala na oszacowanie wartości parametru θ .

4.1 Metoda momentów

Metoda momentów polega na przyrównaniu kolejnych d momentów m_1, \dots, m_d do odpowiednich momentów rozkładu populacji $E(X^i) : i \in [1, d]$

4.2 Metoda największej wiarygodności

Funkcję $L(\theta, x) = p_\theta(x)$ nazywamy funkcją wiarygodności. Estymatorem największej wiarygodności parametru θ nazywamy statystykę $\hat{\theta}$ która maksymalizuje funkcję wiarygodności.

$$\forall_{x \in X} L(\hat{\theta}, x) = \sup_{\theta \in \Theta} L(\theta, x)$$

4.3 Przykład

Estymatorem największej wiarygodności oraz metody momentów dla rozkładu wykładniczego z parametrem λ jest:

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

4.4 Estymatory nieobciążone

Estymator $\hat{\theta}$ nazywamy nieobciążonym, jeżeli $E(\hat{\theta}) = \theta$

4.5 Estymator modelu wykładniczego

Dla modelu wykładniczego, parametryzowanego przez λ , estymatorem nieobciążonym jest:

$$\hat{\lambda} = \frac{n-1}{n} \frac{1}{\bar{X}}$$

4.6 Estymator modelu normalnego

Dla modelu normalnego, parametryzowanego przez μ i σ^2 , estymatorem nieobciążonym jest:

$$\hat{\mu} = \bar{X}$$

$$\hat{\sigma}^2 = S^2$$

4.7 Metoda monte carlo

Niech X' będzie próbą populacji o rozkładzie P_θ , oraz niech $\hat{\theta}$ będzie estymatorem parametru θ . Załóżmy też, że mamy k niezależnych realizacji próby x_1, \dots, x_k . Wtedy histogram wartości \hat{x}_n : $n \in [1, k]$ jest przybliżeniem rozkładu $\hat{\theta}$.

4.8 Metoda bootstrap

Dystrybucja empiryczna to statystyka o następującej postaci:

$$\hat{F}(x) = \frac{\#\{k : X_k \leq x\}}{n}$$

Dla takiej dystrybucji i próby X' zachodzi:

$$\sup_{x \in \mathbb{R}} |\hat{F}(x) - F(x)| \xrightarrow{1} 0$$

Próba bootstrapowa X^* to próba losowa z rozkładu empirycznego. Ta próba musi powstać w wyniku n -krotnego losowania z zwracaniem. Rozkład statystyki $T(X^*) - \hat{\theta}$ jest bliski rozkładowi statystyki $T(X) - \theta$.

Mając k realizacji prób bootstrapowych X_1^*, \dots, X_k^* , możemy przybliżyć rozkład statystyki $\hat{\theta} - \theta$, poprzez stworzenie histogramu $\hat{\theta}^*_{*n}$: $n \in [0, k]$

5 Przedziały ufności

Przedział ufności to przedział $[L, R]$ określony parą statystyk, takich, że:

$$P_\theta(L < \theta < R) = 1 - \alpha$$

gdzie α to poziom ufności, a θ to parametr modelu.

Funkcję $Q(X, \theta)$ nazywamy funkcją centralną dla parametru θ , jeżeli rozkład prawdopodobieństwa zmiennej Q jest absolutnie ciągły i nie zależy od parametru θ , oraz funkcja Q jest ciągła i ściśle monotoniczna względem θ .

Obieranie przedziału ufności następuje poprzez rozwiązanie nierówności:

$$a < Q(X, \theta) < b$$

gdzie a i b się z reguły dobiera tak aby:

$$P(Q \leq a) = P(Q \geq b) = \frac{\alpha}{2}$$

6 Test t-Studenta

6.1 Dla jednej próby

- Hipoteza zerowa: $H_0 : \mu = \mu_0$
- Hipotezy alternatywne: $H_1 : \mu \neq \mu_0$, $H_1 : \mu > \mu_0$, $H_1 : \mu < \mu_0$
- Statystyka testowa:

$$t = \frac{\bar{X} - \mu_0}{S} \sqrt{n}$$

- Rozkład statystyki testowej: $t|_{H_0} \sim t(n-1)$

6.2 Dla dwóch prób

Posiadamy obserwacje jednej zmiennej (cechy) na jednostkach eksperymentalnych pochodzących z dwóch populacji (grup) lub posiadamy dwukrotne obserwacje tej samej zmiennej na tych samych jednostkach eksperymentalnych jednej populacji. Wyróżniamy dwa rodzaje prób: niezależne oraz zależne.

6.2.1 Błąd

Błąd to różnica między wartością zmiennej a wartością przewidywaną przez model. Zakładamy, że błąd:

- ma rozkład normalny
- jest niezależny od zmiennej
- ma wartość oczekiwaną równą 0
- ma stałą wariancję

6.2.2 Próby niezależne z jednorodnymi wariancjami

$$\hat{\mu}_1 = \bar{X}_1$$

$$\hat{\mu}_2 = \bar{X}_2$$

$$\hat{\sigma}^2 = S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

$$S_i^2 = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (x_{ij} - \bar{X}_i)^2$$

- **Hipoteza zerowa:** $H_0 : \mu_1 = \mu_2$
- Hipotezy alternatywne: $H_1 : \mu_1 \neq \mu_2$, $H_1 : \mu_1 > \mu_2$, $H_1 : \mu_1 < \mu_2$
- Statystyka testowa:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{S} \sqrt{\frac{n_1 n_2}{n_1 + n_2}}$$

- Rozkład statystyki testowej: $t|_{H_0} \sim t(n_1 + n_2 - 2)$

6.2.3 Próby niezależne z różnymi wariancjami

$$\hat{\mu}_1 = \bar{X}_1$$

$$\hat{\mu}_2 = \bar{X}_2$$

$$\hat{\sigma}_1^2 = S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (x_{1i} - \bar{X}_1)^2$$

$$\hat{\sigma}_2^2 = S_2^2$$

- **Hipoteza zerowa:** $H_0 : \mu_1 = \mu_2$
- Hipotezy alternatywne: $H_1 : \mu_1 \neq \mu_2$, $H_1 : \mu_1 > \mu_2$, $H_1 : \mu_1 < \mu_2$
- Statystyka testowa:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

- Rozkład statystyki testowej: $t|_{H_0} \sim t(m)$ (test Welch)

7 Test F

Będziemy zakładać dwie różne wariancje dla dwóch prób.

- **Hipoteza zerowa:** $H_0 : \sigma_1^2 = \sigma_2^2$
- Hipotezy alternatywne: $H_1 : \sigma_1^2 \neq \sigma_2^2$, $H_1 : \sigma_1^2 > \sigma_2^2$, $H_1 : \sigma_1^2 < \sigma_2^2$
- Statystyka testowa:

$$F = \frac{S_1^2}{S_2^2}$$

- Rozkład statystyki testowej: $F|_{H_0} \sim F(n_1 - 1, n_2 - 1)$